

Gustavo Berny

Engenheiro de Software Sênior · IA Aplicada e Agentes

Agentes de IA · RAG/pgvector · Claude Code · Node.js/TypeScript · PHP/Laravel · Python · PostgreSQL · React
(51) 98151-8112 | pelotas.berny93@gmail.com | linkedin.com/in/gustavo-berny | gustavoberny.com

PERFIL

Desenvolvedor com mais de 10 anos de experiência, atuando fullstack com base backend sólida em **Node.js/TypeScript** e **PHP/Laravel (MVC)**. Nos últimos anos venho concentrando meu trabalho em **Inteligência Artificial aplicada a produto**: sou o desenvolvedor principal e arquiteto de uma plataforma SaaS multi-tenant de **agentes de IA** em produção — pipeline **RAG** com **pgvector**, orquestração assíncrona de agentes, **tool calling** e **MCP**, com guardrails, observabilidade e controle de custo por tenant. A plataforma roda em produção processando **~153 mil mensagens/mês**, com **85% dos atendimentos resolvidos sem intervenção humana**. Também uso agentes de codificação como parte central do meu processo de engenharia.

Trabalho na interseção entre engenharia e visão de produto — vindo de experiência como **Product Owner**, penso arquitetura sempre com o usuário e o resultado de negócio em mente. Isso me permite avaliar onde IA gera valor real e onde é só ruído, entregando soluções que sustentam operação, custo e qualidade em produção.

PRINCIPAIS COMPETÊNCIAS

- IA & Agentes:** agentes de IA em produção, RAG com pgvector, orquestração multi-agente, tool/function calling, MCP (cliente e servidor), guardrails, IA multimodal, LLMops/FinOps.
- Backend & Arquitetura:** Node.js/TypeScript (ESM), Express, Prisma, PHP/Laravel (MVC), APIs RESTful escaláveis, arquiteturas multi-tenant, filas com RabbitMQ e tempo real com Socket.io.
- Automação & Integrações:** Python para automação de processos e tratamento de dados; integrações com WhatsApp (Z-API e Meta Cloud API), APIs externas e sistemas de terceiros.
- Banco de Dados:** Modelagem e consultas SQL em PostgreSQL e MySQL, busca vetorial com pgvector, otimização via functions, triggers e CTEs.
- Frontend:** React, Vite, Tailwind, Redux Toolkit, design system próprio, JavaScript (ES6+), HTML5 e CSS3.
- Qualidade & DevOps:** Vitest/Jest, testes unitários, de integração e E2E com Testcontainers, property-based testing, Docker, CI/CD, Sentry e métricas Prometheus.
- Segurança:** JWT, API keys por tenant, criptografia de credenciais, rate limiting, proteção contra SSRF e trilha de auditoria.

PROJETO EM DESTAQUE

Agents-IA — Plataforma SaaS de Agentes de IA · Imply

03/2026 – Atual

Plataforma multi-tenant de atendimento em que empresas configuram agentes de IA que conversam de forma autônoma com leads e clientes, com repasse para atendente humano (**human-in-the-loop**) quando necessário. Canais: WhatsApp, widget web embarcável, e-mail, API pública e MCP. Atuei como desenvolvedor principal e arquiteto, com mais de **2.400 commits** e responsabilidade de ponta a ponta — da arquitetura de IA à infraestrutura em produção. Em operação com 11 tenants provisionados (7 ativos), 113 operadores e 126 agentes de IA configurados.

- Entreguei 85% dos atendimentos resolvidos ponta a ponta pela IA**, sem qualquer intervenção humana (6.570 de 7.725 encerrados em ago/2026; 83,3% nos últimos 90 dias), operando ~153 mil mensagens e ~7,8 mil atendimentos por mês — crescimento de 24× em 4 meses.
- Reduzi o tempo de primeira resposta ao cliente de 2min39 para 4,7 segundos** (mediana, -97%), medido sobre 61 mil pares pergunta-resposta em produção.
- Arquitetei camada multi-provider de LLM** (OpenAI, Anthropic e OpenWebUI) atrás de interface comum, com retry, detecção de capacidades por modelo e troca de provider sem alterar o código de negócio.
- Construí pipeline RAG próprio:** chunking customizado, embeddings, busca vetorial em PostgreSQL 16 com pgvector, cache de embeddings de query, versionamento e log de acesso da base de conhecimento.
- Desenvolvi orquestrador assíncrono de agentes** com pipeline de 14 etapas consumido de fila RabbitMQ — carga do agente, busca RAG, chamada ao LLM, execução de tools, guardrails e envio.
- Implementei tool calling** com registry de ferramentas, execução HTTP com credenciais criptografadas, preview, memória de tool e log de cada chamada; e **MCP (cliente e servidor)** com catálogo, adapter de tools e guarda de URL/SSRF.
- Projetei roteamento inteligente de agentes** com 7 níveis de prioridade (conversa ativa, regras de roteamento, menu interativo, agente padrão, autoAssume), além de intent router e debouncer de mensagens.
- Apliquei guardrails de produção** (filtro de conteúdo, bloqueio de URLs não autorizadas, proteção contra vazamento de IDs internos e validação de argumentos de tools) e recursos multimodais: transcrição de áudio, visão computacional, extração de PDF/DOCX, tradução e detecção de idioma.

- **Instrumentei LLMOps/FinOps:** consumo de tokens e cálculo de custo por tenant e por modelo, com tabela de preços versionada e dashboards de uso, mantendo o custo de inferência em US\$ 0,12 por atendimento completo (810 milhões de tokens/mês); além de análise de sentimento, classificação de atendimentos e métricas de SLA.
- **Sustentei qualidade em escala:** monorepo de ~107 mil linhas e 1.019 arquivos, 69 modelos Prisma e 109 migrations, ~3.250 casos de teste (Vitest, Testcontainers, property-based testing) com threshold de 80% de cobertura e verificação de arquitetura no CI.
- **Stack:** Node 22, TypeScript, Express 5, Prisma 6, Zod, React 19, Vite 6, Tailwind 4, PostgreSQL 16 + pgvector, Redis, RabbitMQ, Socket.io, Docker, Bitbucket Pipelines, Oracle Cloud (OCI), Sentry e Prometheus.

EXPERIÊNCIA PROFISSIONAL

Engenheiro Backend Sênior & Líder de Projeto — ImPLY

02/2025 – Atual

- **Plataforma de Agentes de IA (Agents-IA):** liderança técnica e desenvolvimento de ponta a ponta da plataforma detalhada acima — arquitetura de IA, backend, frontend e infraestrutura.
- **Liderança Técnica:** detalhamento de backlog, definição de padrões de arquitetura e alinhamento do time, assegurando que todos compreendam o que precisa ser feito e por quê.
- **Desenvolvimento com IA Aplicada:** uso de Claude Code com agentes paralelos em worktrees git isoladas, reduzindo drasticamente o tempo de entrega sem abrir mão de revisão e qualidade.

Desenvolvedor Fullstack — BernyFlow (Projeto Próprio / SaaS)

02/2025 – Atual

- **SaaS de Gestão Empresarial:** desenvolvimento fullstack com CRM, faturamento e relatórios financeiros. Infraestrutura Docker, autenticação JWT, APIs REST e módulo financeiro com emissão de NFC-e.
- **Ciclo acelerado por IA:** do zero à produção em VPS Linux, com mais de 300 deploys em 3 meses atuando sozinho — desenvolvimento assistido por agentes de IA em todo o ciclo.
- **Stack:** Node.js, TypeScript, React, PostgreSQL, Prisma, Docker — bernyflow.com.br

Desenvolvedor Fullstack — Liga dos Vales de Voleibol (Projeto Próprio)

2026 – Atual

- **Portal oficial da liga:** desenvolvi e mantenho o site público do maior campeonato de voleibol de Santa Cruz do Sul — etapas, chaveamento, ranking, mercado de atletas, Hall da Fama e portal de notícias, com área administrativa restrita para a organização.
- **Operação real:** temporada 2026 com etapas masculinas e femininas reunindo mais de 20 equipes, com resultados e classificação publicados a cada etapa.
- **Stack:** Next.js, React, Docker em VPS próprio — ligadosvales.com.br

Desenvolvedor Fullstack Pleno — Sellflux

09/2023 – 01/2025

- **Chatbot com IA:** criação de chatbot de alta performance, integrando busca vetorial em PostgreSQL para otimizar a relevância das respostas.
- **API & Testes:** backend com Node.js e Express, garantindo qualidade e confiabilidade com Jest.
- **Banco de Dados:** otimização de desempenho com uso avançado de functions, triggers e CTEs.
- **Frontend:** interface completa e interativa construída do zero com React.

Desenvolvedor Backend — ImPLY

08/2021 – 09/2023

- **Sistema de Cobrança (PHP/Laravel):** desenvolvimento de sistema completo de controle de cobrança de associados, adaptado para clubes de futebol, utilizando PHP no padrão MVC.
- **Transações Financeiras:** arquitetura e supervisão de um sistema de débito em conta para mais de 107.000 membros, com transações mensais superiores a R\$ 4 milhões.
- **Integrações & Automação:** soluções para controle de fluxo de caixa, impressão de documentos e regras de acesso e cobrança, com PHP, JavaScript e XML.
- **Controle de Acesso:** sistema de gestão de estacionamento processando mais de 4.000 veículos por dia.

Analista de Suporte Técnico — RM Software

02/2015 – 04/2020

- **Sistemas ERP:** suporte, implementação e treinamento de usuários em sistemas de gestão de contas, faturas, documentos fiscais e cálculo de impostos, propondo melhorias a partir do feedback dos usuários.

FORMAÇÃO

- **Ciência de Dados** — Unopar (em andamento)
- **Técnico em Informática** — UNISC, Santa Cruz do Sul

IDIOMAS

- **Inglês:** Avançado — comunicação fluida em contextos profissionais e técnicos. | **Português:** Nativo.